

Spark 其他开源系统



董西成 2017年5月

Alluxio 2) **Spark JobServer** 3 Zeppelin 总结



1	Alluxio	
2	Spark JobServer	
3	Zeppelin	
4	总结	




Alluxio是什么?

- >一个虚拟分布式文件系统;
- ▶架构在底层分布式文件系统和上层分布式 计算框架之间的一个中间件;
- ➤以文件形式在内存或其它存储设施中提供 数据的存取服务。
- ➤官网链接:http://www.alluxio.org/




Tied Storage





Alluxio生态系统



Case Study: Baidu

Baidu Queries Data 30 Times Faster with Alluxio

- Application: Spark
- Alluxio Storage: MEM + HDD
- Backend Storage: Baidu's File System
- 200+ nodes deployment, 2PB+ managed space
- Result: Speeding up data querying by 30x



1)	Alluxio	
2	Spark JobServer	
3	Zeppelin	
4	总结	



什么是Spark JobServer

- ▶"Spark as Service": 针对 job 和 contexts 的各个方面提供了 REST 风格的 api 接口进行管理(用REST提交、杀死以及管理spark作业)
- ▶通过长期运行的job contexts支持亚秒级别低延迟的任务
- ▶可以通过结束 context 来停止运行的作业(job)
- ▶分割 jar 上传步骤以提高 job 的启动速度
- ▶异步和同步的 job API,其中同步 API 对低延时作业非常有效
- ▶支持 Standalone Spark 和 Mesos、yarn
- ▶对RDD或DataFrame对象命名并缓存,通过该名称获取RDD或 DataFrame。这样可以提高对象在作业间的共享和重用
- ➤官网链接: https://github.com/spark-jobserver/spark-jobserver

Spark JobServer Job实例

```
* A super-simple Spark job example that implements the SparkJob trait and
* can be submitted to the job server.
*/
object WordCountExample extends SparkJob {
 override def validate(sc: SparkContext, config: Config): SparkJobValidation = {
   Try(config.getString("input.string"))
      .map(x => SparkJobValid)
      .getOrElse(SparkJobInvalid("No input.string"))
 override def runJob(sc: SparkContext, config: Config): Any = {
   val dd = sc.parallelize(config.getString("input.string").split(" ").toSeq)
   dd.map(( , 1)).reduceByKey( + ).collect().toMap
```




Spark JobServer Job提交

```
curl --data-binary @../target/mydemo.jar localhost:8090/jars/demo
OK[11:32 PM] ~
curl -d "input.string = A lazy dog jumped mean dog" 'localhost:8090/jobs?
appName=demo&classPath=WordCountExample&sync=true'
 "status": "OK",
 "RESULT": {
    "lazy": 1,
    "jumped": 1,
    "A": 1,
    "mean": 1,
    "dog": 2
```



Spark JobServer加速Job运行






3 Zeppelin




Zeppelin: 基于web的一站式数据科学平台

- >数据探索和发现
- ▶官网链接: http://zeppelin.apache.org/
- ▶与Spark和Hadoop深度集成
- >插件化解释器



Zeppelin: 插件化架构





hadoop123:董西成的微信公众号

专注于Hadoop/spark等大数据相关技术的分享





Q&A? Thank You!